Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa – IDP
Curso de Mestrado Profissional em Administração Pública

Arquitetura de IA Generativa com RAG e Cálculo Determinístico para Democratização da Assessoria em Renda Fixa em Bancos Públicos

Kelsen de Moura Espíndola
Orientador: Prof. Dr. Alex Lopes Pereira

Brasília-DF
2026

KELSEN DE MOURA ESPÍNDOLA

Arquitetura de IA Generativa com RAG e Cálculo Determinístico para Democratização da Assessoria em Renda Fixa em Bancos Públicos

Dissertação apresentada ao programa de pós-graduação em Administração Pública, como parte do requisito para a obtenção do título de Mestre em Administração Pública pelo Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa – IDP.

Área de concentração: Administração Pública

Orientador(a): Prof. Dr. Alex Lopes Pereira

Brasília-DF
2026

ESPÍNDOLA, Kelsen de Moura

Arquitetura de IA Generativa com RAG e Cálculo Determinístico para Democratização da Assessoria em Renda Fixa em Bancos Públicos / Kelsen de Moura Espíndola. – Brasília: IDP, 2026.

00 p.
Inclui bibliografia.

Trabalho de Conclusão de Curso (Dissertação) – Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa – IDP, Curso de Mestrado Profissional em Administração Pública, Brasília, 2026.
Orientador: Prof. Dr. Alex Lopes Pereira.

1. Inteligência Artificial Generativa. 2. Retrieval-Augmented Generation. 3. Renda Fixa. 4. Bancos Públicos. 5. Administração Pública. I. Título.

CDD: a definir

Ficha catalográfica elaborada pela Biblioteca Ministro Moreira Alves
Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa – IDP

A Biblioteca Ministro Moreira Alves oferece o serviço de elaboração de fichas catalográficas; solicite via e-mail para biblioteca@idp.edu.br

KELSEN DE MOURA ESPÍNDOLA

Arquitetura de IA Generativa com RAG e Cálculo Determinístico para Democratização da Assessoria em Renda Fixa em Bancos Públicos

Dissertação apresentada ao programa de pós-graduação em Administração Pública, como parte do requisito para a obtenção do título de Mestre em Administração Pública pelo Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa – IDP.

Área de concentração: Administração Pública

Orientador(a): Prof. Dr. Alex Lopes Pereira

Brasília, a definir.

Banca Examinadora

Prof. Dr. Alex Lopes Pereira
Orientador

Prof. Dr. Claudiomar Matias Rolim Filho
Avaliador

Prof. Dr. Danny de Castro Soares
Avaliador

Dedico aos meus pais, por todo amor, confiança e apoio em toda a minha vida.
Dedico também a todos que estiveram comigo durante a realização do meu curso.

AGRADECIMENTOS

Agradeço à minha família, pelo apoio incondicional em todos os momentos desta caminhada.

Ao meu orientador, Prof. Dr. Alex Lopes Pereira, pela paciência, pela generosidade intelectual e pelo rigor com que conduziu a orientação deste trabalho.

Aos professores e servidores do Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa – IDP, pela formação recebida.

Aos colegas de turma, pelas discussões que ajudaram a amadurecer as ideias aqui apresentadas.

“A ciência é feita de dados como uma casa é feita de pedras. Mas um amontoado de dados não é ciência, assim como um monte de pedras não é uma casa.”

(POINCARÉ, 1902, p. 141)

RESUMO

O mercado de assessoria de investimentos no Brasil apresenta um duplo gargalo de distribuição: ferramentas automatizadas tradicionais limitam-se a questionários estáticos de *suitability*, enquanto modelos de Inteligência Artificial (IA) Generativa pura apresentam risco de alucinação matemática incompatível com um ambiente regulado. Nesse contexto, bancos públicos brasileiros enfrentam um gargalo de capacidade estatal para escalar a assessoria financeira qualificada ao seu público de perfil popular. O tema desta pesquisa é uma arquitetura de IA Generativa com recuperação de conhecimento (*Retrieval-Augmented Generation*, RAG) e cálculo determinístico para democratizar a assessoria em renda fixa em bancos públicos. A pergunta de pesquisa é se uma arquitetura de agente único que, por meio de *function calling*, separa o cálculo quantitativo em Python da geração de linguagem por *Large Language Model* (LLM) e recupera normativos vigentes de uma base RAG é capaz de oferecer orientação em renda fixa a clientes pessoa física de bancos públicos com precisão numérica verificável e conformidade à Resolução CVM nº 30/2021. A pesquisa adota abordagem multimétodos, apoiada na metodologia *Design Science Research*, combinando mapeamento qualitativo de demandas do investidor de varejo, validação técnica dos módulos de cálculo e da base de conhecimento regulatória, *backtesting* histórico de 12 meses e avaliação técnica automatizada por comparação com padrões de referência. Espera-se demonstrar que a arquitetura proposta é capaz de produzir orientações tecnicamente adequadas, contribuindo para a literatura de IA aplicada à Administração Pública e para a democratização do acesso à assessoria financeira no varejo bancário público.

Palavras-chave: Inteligência Artificial Generativa. Retrieval-Augmented Generation. Assessoria Financeira. Bancos Públicos. Renda Fixa. Administração Pública.

ABSTRACT

Brazil's investment advisory market suffers from a twofold distribution gap: traditional automated tools are limited to static suitability questionnaires, while pure Generative Artificial Intelligence (AI) models present a risk of mathematical hallucination that is incompatible with a regulated environment. In this context, Brazilian public banks face a state-capacity bottleneck in scaling qualified financial advisory services to their retail client base. The theme of this research is a Generative AI architecture with Retrieval-Augmented Generation (RAG) and deterministic calculation to democratize fixed-income advisory in public banks. The research question is whether a single-agent architecture that, through function calling, segregates quantitative calculation in Python from natural-language generation by a Large Language Model (LLM) and retrieves regulations in force from a RAG knowledge base can offer fixed-income guidance to public bank retail clients with verifiable numerical accuracy and compliance with CVM Resolution No. 30/2021. The research adopts a mixed-methods approach, grounded in the Design Science Research methodology, combining qualitative mapping of retail investor needs, technical validation of the calculation modules and the regulatory knowledge base, a 12-month historical backtest, and automated technical evaluation against reference benchmarks. The study expects to demonstrate that the proposed architecture is capable of producing technically adequate guidance, contributing to the literature on AI applied to Public Administration and to the democratization of access to financial advisory services in public retail banking.

Keywords: Generative Artificial Intelligence. Retrieval-Augmented Generation. Financial Advisory. Public Banks. Fixed Income. Public Administration.

LISTA DE ILUSTRAÇÕES

Figura 1 – Arquitetura de agente único com segregação entre cálculo determinístico e geração de linguagem 16

LISTA DE TABELAS

Tabela 1 – Corpus normativo da base RAG..... 17

LISTA DE QUADROS

LISTA DE GRÁFICOS

LISTA DE ABREVIATURAS E SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
CDD	Classificação Decimal de Dewey
DPP	Decanato de Pesquisa e Pós-Graduação
IDP	Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa
MEC	Ministério da Educação
RDs	Repositórios Digitais
TCC	Trabalho de Conclusão de Curso

SUMÁRIO

1 INTRODUÇÃO 15
2 REFERENCIAL TEÓRICO 16
3 PROCEDIMENTOS METODOLÓGICOS 17
4 ANÁLISE E DISCUSSÃO DOS DADOS 18
5 CONSIDERAÇÕES FINAIS 19
REFERÊNCIAS 20
APÊNDICE A – Roteiro de entrevista semiestruturada 21
APÊNDICE B – Tabelas complementares 22
ANEXO A – Legislação de referência 23

1 INTRODUÇÃO

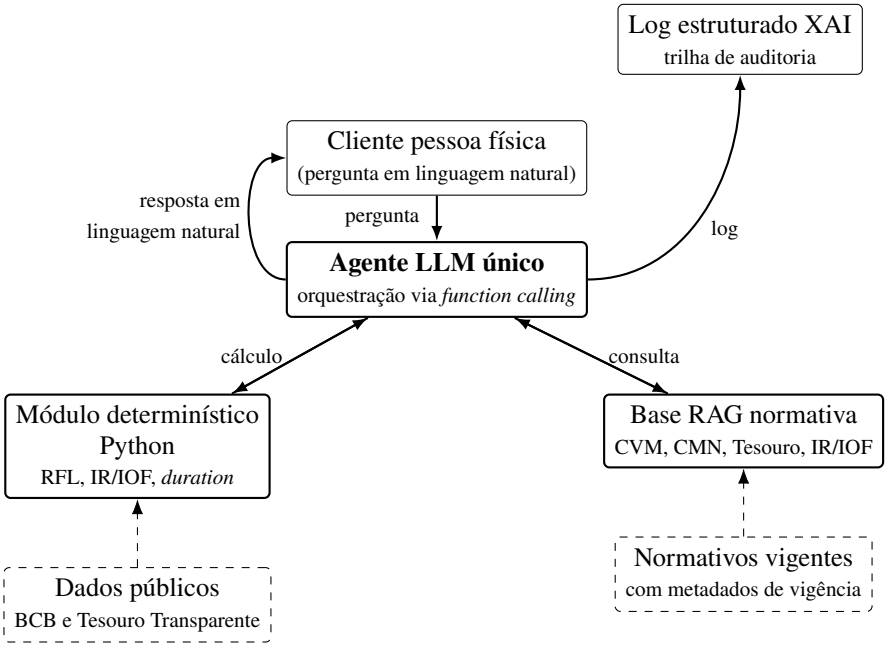
O tema desta pesquisa é o uso de uma arquitetura de Inteligência Artificial (IA) Generativa com recuperação de conhecimento (*Retrieval-Augmented Generation*, RAG) e cálculo determinístico para democratizar a assessoria em renda fixa em bancos públicos. O número de investidores pessoa física cresceu, mas a orientação financeira personalizada e tecnicamente precisa continua acessível sobretudo a clientes de alta renda. Os robôs-investidores tradicionais limitam-se a questionários estáticos de *suitability*, e os modelos de linguagem de larga escala (LLMs) usados sozinhos estão sujeitos a alucinações matemáticas, risco inaceitável em ambiente regulado. Os bancos públicos, federais e regionais como o Banco de Brasília (BRB), têm mandato social e ampla base de correntistas de perfil popular, mas não conseguem ampliar o quadro de especialistas na mesma proporção do crescimento da base de clientes.

Diante desse quadro, a pergunta de pesquisa é a seguinte: uma arquitetura de IA Generativa baseada em agente único que, por meio de *function calling*, separa o cálculo quantitativo em Python da geração de linguagem por LLM e recupera normativos vigentes de uma base de conhecimento regulatória (RAG) é capaz de oferecer orientação em investimentos de renda fixa para clientes pessoa física de bancos públicos com precisão numérica verificável e conformidade à Resolução CVM nº 30/2021, com adequação técnica comprovada por comparação automatizada contra padrões de referência verificáveis? O objetivo geral é desenvolver e validar essa arquitetura, com foco em acessibilidade, precisão numérica verificável e conformidade regulatória, contribuindo para a literatura de IA aplicada à Administração Pública e para a democratização do acesso à assessoria financeira de qualidade.

2 REFERENCIAL TEÓRICO

A técnica de RAG enriquece o contexto do modelo de linguagem com documentos recuperados de uma base de conhecimento indexada, o que reduz o risco de alucinações e atualiza o conhecimento do modelo sem novo treinamento, conforme proposto por Lewis *et al.* (2020). Nesta pesquisa, a RAG se combina com o acoplamento, via *function calling*, de um módulo de cálculo quantitativo determinístico. A Figura 1 sintetiza a arquitetura proposta e mostra a segregação entre o processamento numérico determinístico e a geração de linguagem natural.

Figura 1 – Arquitetura de agente único com segregação entre cálculo determinístico e geração de linguagem



Fonte: Elaborada pelo autor (2026).

No domínio financeiro-regulatório brasileiro, a aplicação de RAG sobre os normativos da Comissão de Valores Mobiliários (CVM), as resoluções do Conselho Monetário Nacional (CMN) e a legislação tributária permite ao agente responder com fundamentação documental rastreável. Esse é um requisito essencial para a conformidade com a Resolução CVM nº 30/2021, que estabelece o dever de verificação da adequação dos produtos, serviços e operações ao perfil do cliente (*suitability*), nos seguintes termos:

> Art. 2º As pessoas habilitadas a atuar como integrantes do sistema de distribuição e os consultores de valores mobiliários não podem recomendar produtos, realizar operações ou prestar serviços sem que verifiquem sua adequação ao perfil do cliente. [...] Art. 3º As pessoas referidas no art. 2º devem verificar se: I – o produto, serviço ou operação é adequado aos objetivos de investimento do cliente; II – a situação financeira do cliente é compatível com o produto, serviço ou operação; e III – o cliente possui conhecimento necessário para compreender os riscos relacionados ao produto, serviço ou operação. (RESOLUÇÃO. . . , 2021, p. 1)

3 PROCEDIMENTOS METODOLÓGICOS

Esta pesquisa adota abordagem multimétodos, de natureza aplicada e caráter exploratório-descritivo. A estratégia de pesquisa segue a metodologia *Design Science Research* (DSR), proposta por Hevner *et al.* (2004), adequada a pesquisas que desenvolvem artefatos tecnológicos com impacto organizacional, por exigir que o artefato resolva um problema real e seja avaliado por critérios de utilidade e rigor científico. A pesquisa usa exclusivamente dados secundários de acesso público, e o sistema é testado com personas sintéticas, perfis de investidor fictícios que não estão vinculados a dados reais de clientes de nenhum banco público.

A base de conhecimento regulatória é formada por um corpus de 14 documentos públicos, organizados em três grupos, que sustentam as regras de *suitability*, de gestão de riscos, de tributação e de linguagem simples aplicadas pelo agente. A Tabela 1 resume esse corpus. A recuperação combina busca por palavras (BM25) e busca semântica por *embeddings*, e cada trecho normativo é indexado com metadados de vigência, para que o agente priorize o dispositivo em vigor e descarte referências a normas superadas.

Tabela 1 – Corpus normativo da base RAG

Grupo	Documento	Regra que sustenta
A	Resolução CVM nº 30/2021	Dever de adequação ao perfil do cliente (*suitability*)
A	Resolução CMN nº 4.557/2017	Gerenciamento de riscos e de capital
A	Resolução CMN nº 4.968/2021	Controles internos
A	Resolução CMN nº 4.879/2020	Auditoria interna
A	Resolução CMN nº 4.893/2021	Política de segurança cibernética
A	Resolução CMN nº 5.274/2025	Alteração da 4.893/2021 (procedimentos e controles mínimos)
B	Lei nº 11.033/2004	Tabela regressiva do IR
B	Decreto nº 6.306/2007	IOF regressivo até 30 dias (art. 32 e Anexo)
B	Lei nº 15.263/2025	Linguagem simples na comunicação com o cidadão
B	Resolução CMN nº 4.222/2013	Garantia do FGC no CDB
C	IN RFB nº 1.585/2015	Base do IR igual ao rendimento bruto deduzido do IOF (art. 46, § 1º)
C	Regulamento do Tesouro Direto, versão de 11/10/2024	Taxa de custódia e isenção do Tesouro Selic até R$ 10.000,00 (itens 137 a 139)
C	Página “Regras e regulamento” do Tesouro Direto	Regras do Tesouro Direto na forma divulgada ao investidor
C	Ato Declaratório do Presidente da Mesa do Congresso Nacional nº 67/2025	Encerramento da vigência da Medida Provisória nº 1.303/2025

Fonte: Elaborada pelo autor (2026).

4 ANÁLISE E DISCUSSÃO DOS DADOS

O módulo de cálculo, escrito em Python puro, foi conferido contra o gabarito do conjunto de casos de cálculo, com o critério de aceite, fixado antes da conferência, de uma diferença de no máximo R$ 0,01 em cada um dos 600 casos. O módulo cumpriu o critério em todos eles, e os 17 testes automatizados, que incluem os casos-limite de prazo zero, de 29 e 30 dias na fronteira do IOF e de taxa de rendimento nula, passam sem acesso à rede. A base regulatória foi dividida em 3.989 trechos, e, nas perguntas de teste, a busca híbrida teve os maiores valores em todas as métricas, exceto no recall@1, em que a busca semântica ficou à frente.

Esses resultados são parciais, porque a avaliação técnica automatizada das respostas do agente ainda depende da execução do experimento. Entre as limitações, a clareza das respostas é validada por LLM-as-a-judge e por métrica de legibilidade, sem validação humana complementar, e 10 das 51 perguntas de teste da base ficaram sem trecho correto entre os 10 primeiros resultados. A discussão também reposiciona o sentido de democratização: para o perfil Sem Reservas, sem capacidade real de investimento, a resposta correta do sistema é não recomendar produto algum, em respeito à vedação da Resolução CVM nº 30/2021 de recomendar produto inadequado ao perfil do cliente.

5 CONSIDERAÇÕES FINAIS

Até aqui, a pesquisa mostrou que o cálculo determinístico do retorno final líquido pode ser separado da geração de linguagem e conferido caso a caso, e que a base de conhecimento regulatória pode ser medida com métricas de recuperação antes de ser integrada ao agente. A resposta completa à pergunta de pesquisa, sobre a precisão numérica e a conformidade à Resolução CVM nº 30/2021 da arquitetura em operação, depende da avaliação técnica automatizada, que permanece pendente no cronograma da pesquisa.

Quanto ao potencial de escala, o módulo de cálculo pode ser reaproveitado sem mudança por outro banco público nos mesmos produtos, e o corpus normativo público vale para qualquer instituição, bastando acrescentar as normas internas e os regulamentos de produto do banco, com nova medição da busca. A agenda de pesquisa futura inclui a validação de experiência de uso com gerentes de *front-office* de bancos públicos, por meio do questionário *System Usability Scale*, e a validação humana em escala antes de qualquer implantação em produção.

REFERÊNCIAS

HEVNER, Alan R. *et al.* Design science in information systems research. **MIS Quarterly**, v. 28, n. 1, p. 75–105, 2004.

LEWIS, Patrick *et al.* Retrieval-augmented generation for knowledge-intensive NLP tasks. *In:* ADVANCES in Neural Information Processing Systems (NeurIPS). [*S. l.: s. n.*], 2020. v. 33, p. 9459–9474.

RESOLUÇÃO CVM nº 30, de 11 de maio de 2021. Dispõe sobre o dever de verificação da adequação dos produtos, serviços e operações ao perfil do cliente (suitability). Rio de Janeiro: CVM, 2021.

APÊNDICE A – ROTEIRO DE ENTREVISTA SEMIESTRUTURADA

Insira aqui o conteúdo do apêndice: questionários, roteiros, formulários de consentimento, transcrições ou qualquer outro material produzido por você.

APÊNDICE B – TABELAS COMPLEMENTARES

Insira aqui o conteúdo do segundo apêndice. Cada chamada de `\apendice{}` gera automaticamente uma nova página e uma entrada no sumário.

ANEXO A – LEGISLAÇÃO DE REFERÊNCIA

Insira aqui o conteúdo do anexo: cópias de leis, pareceres, laudos, mapas ou qualquer material de terceiros que sustente a argumentação do trabalho.